

Классификация комментариев на ревью кода

Результаты

| Модель | Accuracy | Precision | Recall | F1-Score |
|---------------------------------------|----------|-----------|--------|----------|
| Logistic Regression + CountVectorizer | 0.8931 | 0.7111 | 0.7612 | 0.7350 |
| Logistic Regression + TF-IDF | 0.8811 | 0.6605 | 0.8012 | 0.7239 |
| Random Forest + CountVectorizer | 0.8625 | 0.6295 | 0.7162 | 0.6699 |
| Random Forest + TF-IDF | 0.8528 | 0.6031 | 0.7171 | 0.6550 |
| RoBERTa | 0.9198 | 0.8157 | 0.7624 | 0.7881 |
| CodeBERT | 0.9229 | 0.8228 | 0.7723 | 0.7967 |

Проблемы и их решения

Дисбаланс классов

Проблема: Датасет несбалансирован — токсичных комментариев всего 20.3%.

Решение:

- Использована стратифицированная выборка при разбиении train/test
- Рассмотрена возможность применения `class_weight='balanced'` в Logistic Regression
- Для трансформеров: мониторинг метрик на каждом классе отдельно

Вычислительные ресурсы

Проблема: Обучение трансформеров требует GPU.

Решение:

- Использовался Google Colab с бесплатным GPU (Tesla T4)
- Включена mixed precision training (`fp16=True`) для ускорения
- Уменьшен `max_length` до 128 токенов (вместо 512)
- Batch size ограничен 16 для экономии памяти

Долгое обучение трансформеров

Облачные ресурсы в google colab все равно имеют малую производительность и лимиты по использованию

Решение:

- Использовал early stopping (`patience=2`)

Очистка датасета связанная с чувствительной лексикой

Словарь который был представлен в репо ToxicCR имел синтаксические ошибки, в строках лежали просто объект `str`, когда на самом деле это было регулярное выражение (`r-строка` в python)

Решение:

- Отформатировать исходную структуру данных, было принято решение этого не делать.
- Потенциально это может повысить точность моделей.

Итог

Дальнейшие улучшения:

- Собрать больше данных, особенно токсичных комментариев
- Использовать аугментацию данных (`back translation`, `paraphrasing`)
- Ensemble методы: комбинировать предсказания нескольких моделей
- Fine-tuning трансформеров дольше (5-10 эпох) с early stopping
- Гиперпараметрическая оптимизация (Grid Search, Bayesian Optimization)

Все графики располагаются в директориях `4_results`, `3_transformers`, `2_classical_models`.
